

Kauê Oliveira dos Anjos, Felipe Ramos Victor

Previsão Direcional do Bitcoin em Janelas de Cinco Minutos Utilizando Cadeias de Markov

São Paulo

2026

Kauê Oliveira dos Anjos, Felipe Ramos Victor

Previsão Direcional do Bitcoin em Janelas de Cinco Minutos Utilizando Cadeias de Markov

Proposta de Trabalho de Conclusão de Curso
apresentada ao SENAC Santo Amaro como
requisito parcial para aprovação na disciplina
de TCC1 do curso de Bacharelado em Ciência
da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Bacharelado em Ciência da Computação

Orientador: Prof. Thyago Conchado Quintas
Coorientador: Prof. Alessandro Ranulfo Lima Nery

São Paulo
2026

Lista de ilustrações

Figura 1 – Transações modelo bitcoin	13
Figura 2 – Transações modelo bitcoin	14
Figura 3 – Funcionamento do serviço de timestamp	15
Figura 4 – Modelo ilustrativo para a generalização dos estados.	23
Figura 5 – Representação do processo do algoritmo <i>Forward</i> para uma sequência de três observações.	25
Figura 6 – Comparação do número de ocorrências de sequências de tamanho k para 5^k	31
Figura 7 – Erro médio obtido na predição para k dimensões e 5 símbolos	32
Figura 8 – Erro médio obtido na predição para k dimensões e 3 símbolos	32
Figura 9 – Pipeline da solução proposta	38
Figura 10 – Cronograma de atividades – Diagrama de Gantt	39

Lista de abreviaturas e siglas

BIC	<i>Bayesian Information Criterion</i> (Critério de Informação Bayesiano)
BTC	<i>Bitcoin</i>
EM	<i>Expectation-Maximization</i> (Maximização da Expectativa)
HMM	<i>Hidden Markov Model</i> (Modelo Oculto de Markov)
LDA	<i>Linear Discriminant Analysis</i> (Análise Discriminante Linear)
LSTM	<i>Long Short-Term Memory</i>
MAE	<i>Mean Absolute Error</i> (Erro Médio Absoluto)
MAPE	<i>Mean Absolute Percentage Error</i> (Erro Percentual Absoluto Médio)
ML	<i>Machine Learning</i> (Aprendizado de Máquina)
MTD	<i>Mixture Transition Distribution</i> (Mistura de Distribuições de Transição)
QDA	<i>Quadratic Discriminant Analysis</i> (Análise Discriminante Quadrática)
RMSE	<i>Root Mean Square Error</i> (Raiz do Erro Quadrático Médio)
SVM	<i>Support Vector Machine</i> (Máquina de Vetores de Suporte)
XGBoost	<i>Extreme Gradient Boosting</i>

Sumário

1	INTRODUÇÃO	6
1.1	Motivação	8
1.2	Hipótese	9
1.3	Objetivo	9
1.3.1	Objetivo principal	9
1.3.2	Objetivos secundários	9
2	REVISÃO BIBLIOGRÁFICA	11
2.0.1	Metodologia da pesquisa bibliográfica	11
2.0.1.1	Estratégia 1: Criptomoedas e Fatores Macroeconômicos	11
2.0.1.2	Estratégia 2: Predição com Processos Estocásticos	11
2.0.1.3	Triagem Final e Composição do Acervo	12
2.1	Referencial teórico	12
2.1.1	Mercado financeiro e ativos digitais	12
2.1.1.1	Moedas virtuais	12
2.1.1.2	Criptomoedas	12
2.1.1.3	Bitcoin	13
2.1.1.4	Timestamp	14
2.1.1.5	Proof-of-Work	14
2.1.1.6	Rede	15
2.1.2	Macroeconomia e Bitcoin	15
2.1.3	Séries temporais financeiras	15
2.1.3.1	Propriedades de séries temporais financeiras	16
2.1.3.2	Estacionariedade e autocorrelação	17
2.1.3.3	Fatos estilizados dos Retornos financeiros	17
2.1.4	Processos estocásticos e Cadeias de Markov	18
2.1.4.1	Eventos elementares e Aleatórios	18
2.1.5	Variáveis Aleatórias	19
2.1.5.1	Processos estocásticos	19
2.1.5.2	Cadeias de Markov	20
2.1.6	Cadeias de Markov de alta Ordem	21
2.1.7	Modelos Ocultos de Markov (HMM)	22
2.1.7.1	Estados Ocultos e Observáveis	22
2.1.7.2	Componentes do modelo HMM	23
2.1.7.3	Avaliação, Decodificação e Aprendizado	24

2.1.7.4	Algoritmos clássicos	25
2.1.7.4.1	Algoritmo <i>Forward</i>	25
2.1.7.4.2	Algoritmo de Viterbi	26
2.1.7.4.3	Algoritmo de Baum-Welch	27
2.1.7.5	Aplicações de HMM em mercados financeiros e detecção de regimes	28
2.1.8	Discretização e representação simbólica de séries temporais	28
2.1.8.1	Por que discretizar os retornos	28
2.1.8.2	Estratégia de discretização dos dados	29
2.1.8.3	Granularidade e viabilidade estatística	29
2.1.9	Avaliação de modelos preditivos em séries temporais	30
2.2	Trabalhos relacionados	30
2.2.1	Trabalho 1: Reconstructing Cryptocurrency Processes via Markov Chains . .	30
2.2.2	Trabalho 2: Extracting Rules via Markov Chains for Cryptocurrencies Returns Forecasting	33
2.2.3	Trabalho 3: Bitcoin price prediction using machine learning: An approach to sample dimension engineering	34
2.2.4	Síntese Comparativa	35
3	DESENVOLVIMENTO	37
3.1	Solução proposta	37
3.1.1	Visão geral da solução	37
3.1.2	Pipeline da Solução	37
3.2	Cronograma de trabalho	38
	REFERÊNCIAS	40

1 Introdução

Embora sejam popularmente tratadas como dinheiro, as criptomoedas recebem a definição formal restrita de “equivalentes digitais de dinheiro em espécie” ou “moedas digitais conversíveis” (PAPADOPOULOS, 2024). A literatura econômica estabelece que a natureza da moeda deriva de sua utilidade prática como padrão de valor e meio de troca em uma sociedade. Assim, independentemente do debate sobre o potencial de adoção das criptomoedas como substitutas das moedas estatais, o propósito fundamental do Bitcoin e de redes similares é atuar como uma infraestrutura tecnológica para a transmissão online de valor econômico, e não necessariamente exercer a função de moeda (PAPADOPOULOS, 2024).

Conforme observado por Chuen (2024), a próxima geração de sistemas monetários está intrinsecamente ligada ao avanço tecnológico. Nas últimas décadas, o cenário financeiro testemunhou o surgimento de diversas modalidades inovadoras de transações digitais. Esses sistemas de pagamentos alternativos apresentam um crescimento contínuo, consolidando plataformas como *PayPal*, *Apple Pay* e *Google Wallet* como pilares da economia digital contemporânea.

Segundo Chuen (2024, p. 4-5), existem diversas forças socioeconômicas que impulsionam a demanda por moedas alternativas:

- (a) Localismo: ao promover o comércio comunitário [...];
- (b) Tecnologia: tornou-se muito mais fácil de usar com softwares aprimorados [...];
- (c) Economia Política: há desilusão sobre a alta remuneração de CEOs e banqueiros [...];
- (d) Ambientalismo: existem preocupações ecológicas [...];
- (e) Ineficiências: os serviços financeiros estão superfaturados [...];
- (f) Liberdade Financeira: algumas moedas digitais [...] têm a vantagem de transferir valor através da Internet onde o controle é fraco;
- (g) Especulação: compradores de algumas moedas digitais [...] estão antecipando uma valorização de preço. (CHUEN, 2024, p. 4-5)

Dentre as diversas modalidades concebidas para mitigar as ineficiências do sistema tradicional e atender aos anseios por liberdade financeira e oportunidades especulativas, as criptomoedas consolidaram-se como a alternativa digital de maior adoção na sociedade. Conforme argumenta Makarov e Schoar (2022), esses ativos transcenderam seu nicho tecnológico inicial para se tornarem um fenômeno financeiro global, materializando um novo paradigma de descentralização que atrai tanto investidores de varejo quanto institucionais.

As criptomoedas representam uma evolução do conceito de dinheiro eletrônico, fundamentando-se na arquitetura *peer-to-peer* (ponto a ponto). Essa estrutura permite que transações financeiras sejam realizadas diretamente entre as partes, prescindindo da intermediação de instituições bancárias tradicionais (CHUEN, 2024). O Bitcoin, como pioneiro desta classe de ativos, exemplifica uma trajetória de valorização sem precedentes: de um ativo

inicialmente insignificante, o mercado de criptoativos atingiu a marca de USD 3,8 trilhões em janeiro de 2025, com a cotação do Bitcoin superando USD 111.000, apesar de sua característica volatilidade (CHEN, 2025).

Atualmente, as aplicações das criptomoedas transcendem o simples armazenamento de valor, abrangendo áreas como remessas globais, bolsas descentralizadas, jogos digitais e contratos digitais (CHUEN, 2024). Contudo, a identificação dos vetores que impulsionam essas mudanças de preço permanece um desafio. A dinâmica desses ativos é influenciada por um ecossistema multifacetado que envolve desde atualizações tecnológicas e marcos regulatórios até políticas monetárias e a própria psicologia comportamental dos investidores (CHEN, 2025).

Sob a ótica macroeconômica, Blau, Griffith e Whitby (2021) investigou as relações de causalidade do Bitcoin e identificou que variações no preço do ativo precedem mudanças nas expectativas de inflação futura (*forward inflation rates*). É importante notar que a recíproca não foi verificada, sugerindo que o mercado de criptoativos atua como um indicador antecipado, mas não é necessariamente afetado pelas estimativas inflacionárias vigentes. O estudo conclui, ainda, que existem evidências robustas de que crescimentos inesperados no preço do Bitcoin estão associados a aumentos significativos e persistentes nas taxas de inflação esperadas.

Estudos seminais na literatura financeira, como o de Urquhart (2016), apresentaram evidências de que os retornos das séries temporais do Bitcoin possuíam um comportamento próximo ao aleatório, sugerindo uma ineficiência de mercado em seus estágios iniciais. Contudo, pesquisas mais recentes indicam uma mudança nessa dinâmica. Nascimento et al. (2023a) demonstra que as séries temporais de criptoativos possuem, de fato, memória de longo alcance. Além de comprovar a existência dessa dependência temporal, o referido estudo identifica as ordens de Cadeias de Markov que apresentam o melhor desempenho preditivo, utilizando métricas como a Raiz do Erro Quadrático Médio, do inglês *Root Mean Square Error* (RMSE), o Erro Médio Absoluto, do inglês *Mean Absolute Error* (MAE) e o Erro Percentual Absoluto Médio, do inglês *Mean Absolute Percentage Error* (MAPE), as quais garantem a validade dos resultados independentemente da escala dos conjuntos de dados. Estudos como o de Petukhina, Reule e Härdle (2021) apresentam que, por mais que modelos preditivos não dominem por completo o mercado de transações, estes possuem certa expressividade nas transações realizadas.

No que tange à periodicidade dos dados, Nascimento et al. (2023a) fundamenta sua análise em preços de fechamento diários, calculados por meio do retorno logarítmico $\log(Z_t) - \log(Z_{t-1})$. De forma semelhante, Araújo e Barbosa (2024) utiliza a mesma metodologia de retornos, porém aplicada a intervalos de fechamento de uma hora. Em ambos os trabalhos, a discretização das variações é realizada por meio de um alfabeto que classifica diferentes comportamentos. Araújo e Barbosa (2024) utiliza um alfabeto de três caracteres, estabelecendo as seguintes classes: oscilações positivas, pequenas oscilações

não significativas e oscilações negativas. Por sua vez, [Nascimento et al. \(2023a\)](#) emprega alfabetos classificatórios de tamanhos distintos. Ambos os autores concluem que a utilização de alfabetos com muitos caracteres gera inviabilidade estatística e impõe limites computacionais ao treinamento de modelos de predição baseados em Cadeias de Markov.

A presente pesquisa justifica-se pela proposta de transpor essa análise para uma granularidade de alta frequência: intervalos de cinco minutos. Esta escala é estratégica por dois motivos centrais: primeiro, permite investigar se a previsibilidade estatística e a memória do ativo se sustentam na microestrutura do mercado, segundo, fornece o volume de dados necessário para a implementação de modelos estocásticos mais complexos, como Cadeias de Markov de ordens superiores e Modelos Ocultos de Markov, do inglês *Hidden Markov Model* (HMM). A utilização de HMMs, em particular, traz o benefício de traduzir variações comportamentais para a compreensão de cenários de mercado não observáveis diretamente ([MALEKINEZHAD; RAFATI, 2026](#)).

1.1 Motivação

O interesse pelo tema desta pesquisa surgiu da convergência entre o estudo de modelos estocásticos aplicados a séries temporais financeiras e a crescente adoção de sistemas descentralizados de criptomoedas, conforme apontado por [Makarov e Schoar \(2022\)](#). O mercado de criptoativos, em especial o Bitcoin, apresenta um elevado volume transacional e ampla disponibilidade de dados históricos em diversas granularidades, o que viabiliza análises de alta frequência em janelas de tempo reduzidas ([CATANIA; SANDHOLDT, 2019](#)).

Apesar dessa viabilidade para análises mais granulares, a literatura atual que explora a aplicação de Cadeias de Markov no contexto das criptomoedas concentra-se majoritariamente em resoluções mais amplas, como janelas diárias ([NASCIMENTO et al., 2023a](#)) ou horárias ([ARAÚJO; BARBOSA, 2024](#)). Nesse sentido, investigar intervalos de tempo menores, especificamente as janelas de cinco minutos abordadas neste estudo, torna-se um caminho promissor para explorar a dinâmica de alta volatilidade e as características microestruturais inerentes ao Bitcoin ([CATANIA; SANDHOLDT, 2019](#)).

Para extrair valor dessa microestrutura de mercado e de suas oscilações, a modelagem preditiva atua como um ferramental essencial na mitigação de riscos operacionais. Assim como em ativos tradicionais, a capacidade de inferir o comportamento direcional do ativo nessas frações de tempo tão curtas viabiliza a identificação rápida de janelas de oportunidade. Destaca-se, por fim, que uma estratégia financeira se comprova rentável ao sustentar uma vantagem probabilística ao longo do tempo, mesmo quando sujeita aos erros de previsão intrínsecos a qualquer modelo estatístico ([SILVA et al., 2021](#)).

1.2 Hipótese

A hipótese principal deste trabalho é que a sequência de movimentos do Bitcoin, em intervalos de cinco minutos, apresenta dependência temporal suficiente para que uma Cadeia de Markov estime probabilidades de transição capazes de prever a direção do próximo movimento com desempenho superior a modelos ingênuos empíricos, especificamente os modelos aleatório e de persistência.

Como hipótese secundária, investiga-se se a utilização de um HMM, motivada por sua capacidade teórica de inferir estados não observáveis (como potenciais regimes de mercado e volatilidade), oferece um ganho preditivo que justifique sua maior complexidade computacional em comparação às Cadeias de Markov tradicionais.

Enquanto a literatura aponta que o Bitcoin e outras criptomoedas exibem dependência temporal acentuada em janelas diárias (NASCIMENTO et al., 2023a), este estudo busca verificar se tal comportamento persiste em escalas intradia. Adicionalmente, pretende-se identificar a partir de qual ordem da Cadeia de Markov essa dependência se torna estatisticamente relevante para a previsão.

1.3 Objetivo

Esta seção apresenta as diretrizes que norteiam este trabalho, detalhando o propósito central do estudo e os objetivos secundários traçados para o seu alcance.

1.3.1 Objetivo principal

Avaliar a eficácia e identificar componentes de memória de longo alcance em Cadeias de Markov de ordem superior na predição do comportamento direcional do Bitcoin em janelas de cinco minutos, comparando seu desempenho preditivo com modelos de referência (aleatório e de persistência) e com o Modelo HMM.

1.3.2 Objetivos secundários

1. Realizar a coleta e o pré-processamento de dados históricos de cotação do Bitcoin em janelas de cinco minutos;
2. Calcular os retornos logarítmicos da série temporal para extrair as informações de variação e volatilidade;
3. Estabelecer e aplicar um critério de discretização para representar de maneira classificatória os movimentos direcionais do ativo;

-
4. Implementar e treinar modelos de Cadeias de Markov de diferentes ordens, visando identificar a partir de qual ordem a dependência temporal se torna estatisticamente relevante;
 5. Desenvolver e treinar um Modelo HMM para inferir a influência de estados ocultos no comportamento do preço.
 6. Avaliar e comparar o desempenho preditivo dos modelos desenvolvidos em relação aos modelos empíricos de referência (aleatório e de persistência).

2 Revisão Bibliográfica

Este capítulo apresenta a fundamentação teórica necessária para a compreensão e o desenvolvimento deste trabalho, bem como a metodologia de pesquisa bibliográfica adotada para selecionar fontes confiáveis e preencher lacunas de conhecimento. Ao longo do texto, são introduzidas as principais terminologias, propriedades e relações conceituais que embasam a pesquisa, fornecendo o alicerce para as análises e discussões subsequentes.

2.0.1 Metodologia da pesquisa bibliográfica

A metodologia para a seleção bibliográfica deste estudo baseou-se em buscas sistemáticas nas bases de dados *ACM Digital Library*, *IEEE Xplore* e *Science Direct*. O processo foi estruturado em duas frentes estratégicas de investigação principais:

2.0.1.1 Estratégia 1: Criptomoedas e Fatores Macroeconômicos

String de busca: ("Bitcoin" OR "cryptocurrency") AND ("high frequency" OR "intraday" OR "5-minute" OR "tick data") AND ("macroeconomic" OR "inflation")

Critério de Inclusão: Os artigos deveriam citar explicitamente os termos *Bitcoin* ou criptomoedas, em conjunto com economia (ou sinônimos), diretamente no título do trabalho.

Resultados obtidos: *ACM* (307); *IEEE* (13 iniciais, 12 após filtros preliminares); *Science Direct* (1.202 iniciais, 1.104 após filtros preliminares).

2.0.1.2 Estratégia 2: Predição com Processos Estocásticos

String de busca: ("Markov chain" OR "high-order Markov" OR "stochastic process") AND ("cryptocurrency" OR "Bitcoin")

Critério de Inclusão: O estudo deveria aplicar obrigatoriamente uma cadeia de Markov ou outro processo estocástico/estatístico com a finalidade de prever o comportamento ou o preço do *Bitcoin*. Exigiu-se a menção ao método (Markov ou processo estatístico) no título ou no resumo (*abstract*), além da citação direta ao termo *Bitcoin*.

Resultados obtidos: *ACM* (403); *Science Direct* (799 iniciais, 657 após filtros preliminares); *IEEE* (124 iniciais, 84 após filtros preliminares).

2.0.1.3 Triagem Final e Composição do Acervo

Após a coleta inicial, realizou-se uma filtragem rigorosa para descartar os artigos que apresentavam um distanciamento temático ou conceitual do objetivo central da pesquisa.

Com o intuito de preencher lacunas de conhecimento e consolidar uma base teórica robusta, o acervo selecionado foi complementado por meio da inserção manual de referências seminais, livros e artigos clássicos da literatura da área. Ao final de todo o processo de triagem, refinamento e complementação, obteve-se um total de 30 artigos lidos efetivamente na íntegra, os quais compõem o escopo de análise deste estudo.

2.1 Referencial teórico

Esta seção aborda a definição de moedas virtuais, com foco específico nas criptomoedas. Em seguida, são apresentados os fundamentos analíticos do estudo, explicando o comportamento das séries temporais financeiras, as Cadeias de Markov e suas aplicações, bem como os Modelos Ocultos de Markov, do inglês *Hidden Markov Model* (HMM). Por fim, detalha-se o processo de discretização de dados, seguido pela apresentação e justificativa das métricas de avaliação utilizadas.

2.1.1 Mercado financeiro e ativos digitais

2.1.1.1 Moedas virtuais

Moedas virtuais são descritas de acordo com [Chuen \(2024\)](#) como sendo uma das formas alternativas ao sistema clássico de moedas fiduciárias já estabelecido. De acordo com a definição apresentada por [Financial Action Task Force \(2014\)](#), uma moeda virtual é uma representação digital de valor que pode ser negociada digitalmente e exercer funções semelhantes às da moeda, como meio de troca, unidade de conta e reserva de valor, embora, na definição original, não possua curso legal. Um dos meios de pagamentos virtuais mais conhecidos é o bitcoin, que é, na verdade, uma criptomoeda como apontado por [Chuen \(2024\)](#).


2.1.1.2 Criptomoedas

Criptomoedas são definidas como “moedas digitais conversíveis” e em outras legislações como “equivalente digital a dinheiro” ([PAPADOPOULOS, 2024](#)). De todo modo, essas definições são aplicadas às criptomoedas que são convertidas para moedas oficiais utilizando mercados digitais e sites de câmbio. De todo modo, moedas digitais não podem ser consideradas dinheiro sob o olhar clássico ([PAPADOPOULOS, 2024](#)).

2.1.1.3 Bitcoin

Bitcoin foi a primeira criptomoeda de código aberto descentralizada criada, e é uma das formas mais populares para pagamentos digitais (CHUEN, 2024). O Bitcoin é tido como modelo e fonte de código para criptomoedas emergentes, embora nem todas sigam seu modelo, como visto por Papadopoulos (2024). O bitcoin nasce com o trabalho de Nakamoto (2008) com o objetivo de ser uma alternativa aos pagamentos baseados em fidúcia, criando um sistema *peer-to-peer* (ponto a ponto) baseado em provas criptográficas (usando de chaves públicas e privadas), assim permitindo que duas partes efetuem pagamentos sem a necessidade de uma terceira entidade de confiança, formando assim o ponto a ponto. Em seu trabalho Nakamoto (2008) propõe que nós da rede atuem como validadores das transações realizadas dentro do sistema. As transações são definidas como um encadeamento de assinaturas digitais, como podemos observar na Figura 1. Para realizar uma transferência o proprietário remetente transfere o valor assinando o *hash* da transação anterior e a chave pública do proprietário destinatário, adicionando ambos ao final da transação.

Figura 1 – Transações modelo bitcoin




Fonte: (NAKAMOTO, 2008), adaptado pelos autores.

Em seu trabalho Nakamoto (2008) descreve que as transações realizadas no sistema são publicamente anunciadas e a validade das transações se baseia em um mecanismo de consenso baseado em poder computacional (Proof-of-Work). Se a maioria do poder computacional da rede validar um bloco de transações, então este bloco é adicionado ao histórico da rede através de um sistema de validação temporal (timestamp) diferente de outros sistemas que dependem de uma entidade central administradora, cada bloco possui informações sobre os blocos anteriores fazendo assim um encadeamento dos blocos (blockchain). Contudo o sistema precisa de um meio de validar se um proprietário não realizou uma transação dupla, gastando uma mesma moeda duas vezes, e para isso o sistema conta com um serviço chamado timestamp.

2.1.1.4 Timestamp

Para Nakamoto (2008), o *timestamp* não é apenas “data e hora”, mas sim um sistema de validação temporal descentralizado. Esse sistema é responsável por aplicar a função *hash* em blocos de transações, *hash* é uma função matemática criptográfica que transforma qualquer conjunto de dados em uma sequência única de caracteres de tamanho fixo, sendo único para cada bloco. O serviço depois é responsável por divulgar o *hash* do bloco pela rede. Cada novo bloco emitido pelo sistema inclui o *hash* do bloco anterior em sua composição, formando assim uma cadeia (*chain*) onde cada bloco subsequente reafirma a validade dos blocos anteriores. Podemos observar esse funcionamento na Figura 2, onde o serviço de *timestamp* aplica a função a um bloco, depois o hash é propagado e usado para compor a função *hash* do próximo bloco.

Figura 2 – Transações modelo bitcoin



Fonte: (NAKAMOTO, 2008), adaptado pelos autores.


2.1.1.5 Proof-of-Work

Para implementar um serviço timestamp como descrito anteriormente, é utilizado outro sistema, o *Proof-of-Work* (Prova de trabalho). As provas de trabalho envolvem aplicar uma função hash a um bloco e verificar se esse hash começa com uma quantidade específica de zeros. Para chegar em um hash que respeite essa condição é adicionado ao bloco um número que é utilizado apenas uma vez (Nonce) e depois a função hash é aplicada ao bloco, uma vez que o hash não respeite a regra basta escolher outro nonce e aplicar a função hash novamente até que o hash respeite a regra imposta (NAKAMOTO, 2008).

Essa prova de trabalho é essencialmente um modelo de um voto por CPU. O incentivo para que os nós participem da prova de trabalho é que os participantes são recompensados, o primeiro nó a conseguir achar o hash para o bloco receberá moedas criadas recentemente (CHUEN, 2024).

Podemos observar na Figura 3 o funcionamento do encadeamento dos blocos.

Figura 3 – Funcionamento do serviço de timestamp



Fonte: (NAKAMOTO, 2008), adaptado pelos autores.

2.1.1.6 Rede

Os passos de funcionamento da rede são:

1. Novas transações são transmitidas a todos os nós.
2. Cada nó coleta as novas transações e gera um bloco.
3. Cada nó tenta encontrar a prova de dificuldade para seu bloco.
4. Quando um nó encontra a prova de dificuldade ele transmite a prova para toda a rede.
5. Os nós da rede aceitam o bloco transmitido apenas se todas as transações são válidas e não foram gastas anteriormente.
6. Os nós expressam o consenso de aprovação para o bloco usando o para criar o próximo bloco da cadeia, usando o hash do bloco aceito.

2.1.2 Macroeconomia e Bitcoin

Conforme demonstrado por Ben Omrane et al. (2025), análises baseadas em retornos diários mostram-se inadequadas para a avaliação de eventos macroeconômicos em criptoativos. Uma vez que os choques gerados por indicadores de inflação são incorporados nos preços de forma quase instantânea, o recurso a uma frequência diária resultaria no mascaramento dessas reações intradiárias. Portanto, para analisar melhor a volatilidade do Bitcoin, serão usadas janelas de fechamento de 5 minutos, como demonstrado por Gonzalez de Freitas Pinto (2025), o intervalo de 5 minutos possui os resultados mais acurados, intervalos de granularidade mais fina possuem muito ruído o que pode gerar distorção na volatilidade e nos resultados do estudo.

2.1.3 Séries temporais financeiras

Uma série temporal é qualquer conjunto de observações ordenadas no tempo (MORETTIN; TOLOI, 2018). Frequentemente, uma série temporal discreta é obtida pela

amostragem de uma série contínua em intervalos de tempo iguais. É importante notar que aquilo que se denomina série temporal corresponde, na realidade, a apenas uma das muitas trajetórias possíveis que poderiam ter sido observadas a partir de um determinado processo, fenômeno ou evento (MORETTIN; TOLOI, 2018). A série de retornos do Bitcoin configura uma série univariável e unidimensional, isto é, dado o parâmetro tempo t , obtém-se o retorno do ativo no instante correspondente, e sua série descrita sob intervalos de tempo constante configura uma série temporal discreta.

Segundo Morettin e Tolo (2018), a análise de séries temporais pode ser utilizada para alcançar diferentes objetivos, entre os quais se destacam

- investigar o mecanismo gerador da série, isto é, compreender o que origina o dado observado
- realizar previsões de valores futuros, sejam elas de curto ou de longo prazo
- descrever e analisar o comportamento da série, identificando a existência de tendências, ciclos e variações sazonais
- buscar periodicidades relevantes nos dados.

Em diversas áreas do conhecimento como engenharia, ciências exatas e ciências humanas, se utiliza o conceito de sistema dinâmico, que tem como componentes principais uma série de entrada $X(t)$, uma série de saída $Z(t)$ e uma função de transferência $v(t)$. Para estes sistemas, os problemas que podem ser investigados são

- estimar a função de transferência conhecendo-se as séries de entrada e de saída
- prever a série $Z(t)$ a partir das observações de $X(t)$
- Estudar o comportamento do sistema simulando a série de entrada $X(t)$
- controlar a série de saída $Z(t)$ por meio do ajuste conveniente da série de entrada $X(t)$

Os problemas que podem ser resolvidos através da análise de séries temporais são particularmente interessantes para a realização deste trabalho, a análise e entendimento completo da série temporal do Bitcoin e suas propriedades são fundamentais para a modelagem de modelos que realizem a previsão de comportamentos futuros.

2.1.3.1 Propriedades de séries temporais financeiras

As séries financeiras, embora compartilhem da estrutura geral descrita acima, possuem propriedades particulares que as distinguem de outras séries temporais. Em geral, não se trabalha com a série de preços, mas com a série de retornos, por razões tanto estatísticas

quanto econômicas. Uma das transformações mais empregadas é o retorno logarítmico, também denominado retorno composto contínuo, definido como

$$r_t = \log\left(\frac{P_t}{P_{t-1}}\right) = p_t - p_{t-1} = \Delta \log(P_t), \quad (2.1)$$

em que P_t é o preço do ativo no instante t e $p_t = \ln(P_t)$ denota o logaritmo natural do preço nesse mesmo instante (MORETTIN; TOLOI, 2018). A passagem para os retornos logarítmicos confere à série propriedades convenientes para a modelagem, tais como a aditividade temporal e a estabilização da variância. Por exemplo, caso um ativo sofra uma queda de 25% seguida de uma alta de 25%, o valor do ativo irá permanecer inalterado.

2.1.3.2 Estacionariedade e autocorrelação

Uma das suposições mais recorrentes na análise de séries temporais é a de estacionariedade, segundo a qual a série se desenvolve aleatoriamente no tempo em torno de uma média constante, refletindo um comportamento de equilíbrio e constância. Na prática, as séries temporais não costumam apresentar algum tipo de estacionariedade no seu comportamento. As séries financeiras, em particular, costumam exibir tendências, fases de alta, de baixa e de lateralização, o que afasta a propriedade de estacionariedade quando se trabalha diretamente com a série de preços (MORETTIN; TOLOI, 2018).

É justamente esse comportamento que motiva a transformação dos preços em retornos, ao utilizar a diferença de logaritmos se busca uma série mais próxima da estacionariedade, condição que é necessária para grande parte das técnicas de modelagem de sistemas de previsão. Em relação à autocorrelação, os retornos financeiros apresentam um padrão peculiar, sendo, em geral, não autocorrelacionados de maneira linear (MORETTIN; TOLOI, 2018), o que na prática significa que os retornos passados não servem para realizar as previsões na série de maneira linear.

2.1.3.3 Fatos estilizados dos Retornos financeiros

Os retornos financeiros apresentam características peculiares que não se observam em outras séries temporais. Tipicamente, eles não exibem tendências nem sazonalidade. Os principais fatos estilizados podem ser resumidos nos seguintes pontos (MORETTIN; TOLOI, 2018):

1. os retornos são, em geral, não autocorrelacionados de maneira linear;
2. as séries de retornos apresentam agrupamentos de volatilidade ao longo do tempo, de modo que períodos de alta variabilidade tendem a ser seguidos por períodos igualmente voláteis, e vice-versa;
3. a distribuição dos retornos apresenta caudas mais pesadas do que a distribuição normal e, embora aproximadamente simétrica, é em geral leptocúrtica;

2.1.4 Processos estocásticos e Cadeias de Markov

Esta seção destina-se a apresentar parte da fundamentação teórica que dará suporte ao desenvolvimento da pesquisa. O texto introduz a noção geral de processos estocásticos e afunila para a apresentação das Cadeias de Markov, modelo este que será adotado nas etapas seguintes do trabalho, compreendendo suas propriedades e aplicações práticas.

2.1.4.1 Eventos elementares e Aleatórios

O conceito de evento elementar é a noção primitiva na formulação axiomática da teoria das probabilidades. Para cada problema investigado, deve-se definir previamente o que constitui o resultado mais básico e indivisível do experimento, formando assim o universo de possibilidades, que é denominado conjunto de eventos elementares e denotado por E (FISZ, 1963).

Para ilustrar, Fisz (1963) fornece o exemplo do lançamento de um dado de seis faces. Pode-se denotar a ocorrência de uma face específica i (onde $1 \leq i \leq 6$) com a notação e_i . Nesse cenário, cada resultado individual do dado é um evento elementar, tal que $e_i \in E$.

A partir da estrutura de E , estabelece-se um conjunto Z formado por subconjuntos de eventos elementares de E . Esse conjunto Z é denominado campo de Borel, e os elementos que o compõem são chamados de eventos aleatórios desde que a estrutura de Z atenda às seguintes propriedades (FISZ, 1963):

1. O campo Z possui como um de seus elementos o próprio conjunto E em sua totalidade (caracterizando o evento certo).
2. O campo Z possui como um de seus elementos o conjunto vazio $\emptyset$ (caracterizando o evento impossível).
3. Se um número finito ou enumerável de eventos $A_1, A_2, \dots, A_n \in Z$, então a sua união (ou alternativa) também pertence a Z .
4. Se os eventos A_1 e A_2 pertencem a Z , então a sua diferença ($A_1 - A_2$) também pertence a Z .
5. Se um número finito ou enumerável de eventos $A_1, A_2, \dots, A_n \in Z$, então o seu produto (ou interseção) também pertence a Z .

Como observado por Fisz (1963) a conjugação das propriedades 1 e 4 gera uma consequência: evento complementar. Como o conjunto universo E pertence a Z (Propriedade 1) e o campo é fechado para a diferença entre dois de seus elementos (Propriedade 4), então nota-se que a diferença $E - A$ também pertence a Z . Dessa forma, garante-se que, se um determinado evento pertence ao campo de Borel, o seu exato oposto (o seu complemento) também será, obrigatoriamente, um evento aleatório.

2.1.5 Variáveis Aleatórias

Seja E o conjunto de eventos elementares e $e \in E$ um evento elementar. Definimos $X(e)$ como uma função real de valor único sobre o conjunto E , isto é, $X : E \rightarrow \mathbb{R}$. Para um dado subconjunto $S \subseteq \mathbb{R}$, denotamos por A a imagem inversa de S . Uma função X definida no conjunto E é chamada de variável aleatória se a imagem inversa de qualquer intervalo I no eixo real for um evento aleatório. Definimos que a probabilidade de a variável aleatória X assumir um valor dentro do intervalo I é igual à probabilidade de sua imagem inversa A , ou seja:

$$P(X \in I) = P(A) \quad (2.2)$$

(FISZ, 1963)

Um exemplo mais prático de variáveis aleatórias é demonstrado por Ross (2010), no qual se soma o resultado do lançamento de dois dados:

$$\begin{aligned} P(X = 2) &= P(\{(1, 1)\}) = \frac{1}{36} \\ P(X = 3) &= P(\{(1, 2), (2, 1)\}) = \frac{2}{36} \\ P(X = 4) &= P(\{(1, 3), (2, 2), (3, 1)\}) = \frac{3}{36} \\ P(X = 5) &= P(\{(1, 4), (2, 3), (3, 2), (4, 1)\}) = \frac{4}{36} \\ P(X = 6) &= P(\{(1, 5), (2, 4), (3, 3), (4, 2), (5, 1)\}) = \frac{5}{36} \\ P(X = 7) &= P(\{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}) = \frac{6}{36} \\ P(X = 8) &= P(\{(2, 6), (3, 5), (4, 4), (5, 3), (6, 2)\}) = \frac{5}{36} \\ P(X = 9) &= P(\{(3, 6), (4, 5), (5, 4), (6, 3)\}) = \frac{4}{36} \\ P(X = 10) &= P(\{(4, 6), (5, 5), (6, 4)\}) = \frac{3}{36} \\ P(X = 11) &= P(\{(5, 6), (6, 5)\}) = \frac{2}{36} \\ P(X = 12) &= P(\{(6, 6)\}) = \frac{1}{36} \end{aligned}$$

Neste caso X pode assumir um número contável de valores ($2 \leq X \leq 12$), então X é uma variável aleatória discreta.

2.1.5.1 Processos estocásticos

Conforme definido por Fisz (1963) e Ross (2010), um processo estocástico é uma coleção de variáveis aleatórias parametrizadas por t , comumente denotada por $\{X_t, t \in T\}$. O conjunto T é chamado de conjunto de índices do processo e é interpretado como o tempo.

Sendo assim, X_t representa o estado em que o processo se encontra no exato instante t . A classificação estrutural de um processo estocástico depende diretamente da natureza do seu conjunto de índices T . Quando T é um conjunto enumerável, o modelo é categorizado como um processo de tempo discreto. Por outro lado, se T for um intervalo contínuo na reta dos números reais, o processo é classificado como de tempo contínuo. Por fim, o conjunto que engloba todos os valores possíveis que X_t pode assumir ao longo da evolução do sistema é denominado *espaço de estados* do processo (ROSS, 2010).

2.1.5.2 Cadeias de Markov

Conforme Ross (2010), seja $\{X_n, n = 0, 1, 2, \dots\}$ um processo estocástico em que X_n assume valores em um espaço de estados composto por inteiros não negativos. Quando $X_n = i$, diz-se que o processo se encontra no estado i no instante n . Supõe-se que, sempre que o processo está no estado i , existe uma probabilidade fixa P_{ij} de que o próximo estado seja j . Matematicamente, essa condição é expressa por:

$$P(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_1 = i_1, X_0 = i_0) = P_{ij} \quad (2.3)$$

Um processo estocástico que satisfaz a equação para todos os estados $i_0, i_1, \dots, i_{n-1}, i, j$ e para todo instante $n \geq 0$ é denominado Cadeia de Markov (ROSS, 2010). Em outras palavras, o estado futuro X_{n+1} é condicionalmente independente de todo o histórico passado do processo, dependendo exclusivamente do estado presente X_n .

As probabilidades de transição P_{ij} podem ser organizadas em uma matriz $\mathbf{P}$ (ROSS, 2010), estruturada da seguinte forma:

$$\mathbf{P} = \begin{pmatrix} P_{00} & P_{01} & P_{02} & \cdots \\ P_{10} & P_{11} & P_{12} & \cdots \\ \vdots & \vdots & \vdots & \ddots \\ P_{i0} & P_{i1} & P_{i2} & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

Como essas probabilidades representam a chance de transição de um estado para outro, e considerando que o processo obrigatoriamente fará uma transição para algum estado (incluindo a possibilidade de permanecer no mesmo estado atual), os elementos da matriz devem satisfazer as seguintes condições:

$$P_{ij} \geq 0, \quad i, j \geq 0; \quad \sum_{j=0}^{\infty} P_{ij} = 1, \quad i = 0, 1, \dots$$

2.1.6 Cadeias de Markov de alta Ordem

Em seu estudo (URQUHART, 2016) conclui que os retornos do Bitcoin possuem indícios de comportamento aleatório, porém na literatura mais recente (NASCIMENTO et al., 2023a) não só revela evidências de que a série do Bitcoin possui memória como determinam a magnitude dessa memória usando modelos estatísticos. Um modelo de cadeias de Markov de Alta ordem é apresentado por Raftery (1985) como uma alternativa aos modelos convencionais que possuem o número de parâmetros independentes descritos por: $m^l(m-1)$, onde m é o número de estados e l a ordem da cadeia de markov, o modelo introduzido por Raftery (1985) foi posteriormente chamado de Mistura de Distribuições de Transição, do inglês *Mixture Transition Distribution* (MTD), e utiliza de $m(m-1) + (l-1)$ parâmetros independentes e é descrito por:

$$P[X_t = j_0 \mid X_{t-1} = j_1, \dots, X_{t-l} = j_l] = \sum_{i=1}^l \lambda_i q_{j_0 j_i} \quad (2.4)$$

onde a probabilidade condicional de observar o estado j_0 no instante t é expressa como uma combinação linear das contribuições individuais de cada um dos estados passados $(X_{t-1}, X_{t-2}, \dots, X_{t-l})$.

Alternativamente, o modelo pode ser representado em sua forma matricial. Para tanto, define-se o vetor coluna $X_t = (X_t(1), \dots, X_t(m))'$, onde $X_t(j) = 1$ se o processo estiver no estado j no instante t , e 0 caso contrário. Analogamente, seja $\hat{X}_t = (\hat{X}_t(1), \dots, \hat{X}_t(m))'$ o vetor cujos elementos $\hat{X}_t(j)$ representam a probabilidade condicional $P[X_t = j \mid X_{t-1} = j_1, X_{t-2} = j_2, \dots]$. Desse modo, a formulação linear pode ser reescrita como:

$$\hat{X}_t = \sum_{i=1}^l \lambda_i Q X_{t-i} \quad (2.5)$$

Note que, quando $l = 1$, a equação reduz-se a uma cadeia de Markov de primeira ordem clássica com matriz de transição Q . No entanto, adota-se aqui a convenção de Raftery (1985), na qual a soma dos elementos de cada coluna de Q é igual a 1, diferindo do enfoque tradicional estruturado por linhas.

Para chegar nos melhores pesos para cada t Raftery (1985) utiliza do Critério de Informação Bayesiano, do inglês *Bayesian Information Criterion* (BIC), com o objetivo de minimizar esse critério. O BIC é definido como:

$$BIC = -2LL + p \times \log(n) \quad (2.6)$$

onde LL é o logaritmo da função de verossimilhança do modelo, p é o número de parâmetros independentes e n é o número de componentes da função logaritmo de verossimilhança (RAFTERY, 1985)

2.1.7 Modelos Ocultos de Markov (HMM)

Segundo [Ghahramani \(2001\)](#), o HMM é uma ferramenta utilizada para representar distribuições de probabilidades sobre uma sequência de observações dentro de uma série temporal. O objeto observado pode ser um símbolo de um alfabeto discreto, um valor real, um número inteiro ou qualquer outro objeto sobre o qual se possa definir uma distribuição de probabilidade.

Um HMM consiste em dois processos estocásticos: o primeiro é a Cadeia de Markov, caracterizada por estados e probabilidades de transição, onde esses estados não são visíveis externamente (ou seja, são ocultos) e o segundo é um processo estocástico que produz emissões observáveis atreladas a cada um dos estados ([DYMARSKI, 2011](#)).

Os HMMs são comumente utilizados para a análise e observação de séries temporais em diferentes contextos. São aplicados na área de biologia molecular para a identificação de genes ([MA et al., 2026](#)), reconhecimento de fala para a modelagem de fonemas ([JURAFSKY; MARTIN, 2026](#)), dentre outras áreas ([DYMARSKI, 2011](#)). Neste trabalho, utilizaremos um modelo HMM aplicado ao setor financeiro, mais especificamente voltado aos ativos digitais (Bitcoin).

Para compreender a aplicação prática do HMM, é necessário detalhar a relação entre os dados visíveis (emissões observáveis) e os estados ocultos que o sistema infere de maneira indireta.


2.1.7.1 Estados Ocultos e Observáveis

Em um HMM, o modelo é categorizado em dois conjuntos fundamentais, os estados ocultos e as observações (ou estados observáveis). Os estados observáveis correspondem aos dados empíricos extraídos de maneira direta da série temporal, refletindo as medições quantificáveis da realidade. Em contrapartida, os estados ocultos representam a dinâmica interna e estocástica do sistema. Embora sejam invisíveis ao observador externo, esses estados ocultos governam o comportamento do modelo e influenciam diretamente a distribuição de probabilidade responsável por gerar as emissões observáveis a cada instante ([DYMARSKI, 2011](#)). No contexto desta pesquisa, essas emissões observáveis correspondem aos dados empíricos extraídos diretamente da série temporal, refletindo os retornos quantificáveis do ativo.

Podemos entender melhor a dinâmica entre os diferentes estados através do exemplo ilustrado na Figura 4. Suponhamos que temos uma sequência observada de bolas coloridas que são sorteadas em diferentes momentos. Nossos estados observáveis são as cores das bolas que conseguimos ver sair, no exemplo ilustrado, verde (*GREEN*), azul (*BLUE*), vermelho (*RED*) e amarelo (*YELLOW*), formando a sequência de observações *O*.

Nós sabemos que a cor da bola sorteada é influenciada de maneira indireta pela urna da qual ela foi retirada (Urna 1, Urna 2, ..., Urna *N*). Como a urna escolhida a cada passo

Figura 4 – Modelo ilustrativo para a generalização dos estados.



Fonte: (RABINER, 1989)

não é registrada diretamente na nossa sequência de observações (nós enxergamos apenas as cores das bolas sorteadas), essas urnas representam os estados ocultos do nosso sistema, sendo as responsáveis por emitir as probabilidades de observarmos cada cor (representadas pelas funções de emissão $P(COR) = b_n(m)$).

Compreendida a dinâmica intuitiva dos estados, a próxima etapa consiste em formalizar os componentes principais que definem um HMM.

2.1.7.2 Componentes do modelo HMM

O HMM possui características herdadas de outros processos estocásticos, como a Cadeia de Markov. Formalmente, conforme definido por Kuinchtner e Madalozzo (2018), o HMM é caracterizado pelos seguintes componentes:

- N , que representa o número de estados ocultos no modelo;
- $M = \{m_1, m_2, \dots, m_n\}$, que representa o conjunto de observações possíveis (símbolos observáveis), onde estes dependem dos estados. Cada observação possui uma probabilidade distinta associada a cada estado;
- Uma matriz de transição de estados $A = \{a_{ij}\}$, onde $a_{ij} = P(q_{t+1} = S_j \mid q_t = S_i) \forall i, j = 1, 2, \dots, N$, exemplificada na Equação 2.7:

$$A = \begin{pmatrix} a_{i \rightarrow i} & a_{i \rightarrow j} \\ a_{j \rightarrow i} & a_{j \rightarrow j} \end{pmatrix} \quad (2.7)$$

- Uma matriz de probabilidade de emissão B , que representa a distribuição probabilística da emissão de um estado, exemplificada na Equação 2.8, sendo esta a matriz que interliga os estados ocultos aos estados observáveis:

$$B = \begin{pmatrix} b_i(m_1) & b_i(m_2) & b_i(m_3) \\ b_j(m_1) & b_j(m_2) & b_j(m_3) \end{pmatrix} \quad (2.8)$$

- Um vetor π , que representa a distribuição de probabilidade inicial para cada um dos estados do sistema, exemplificado na Equação 2.9:

$$\pi = \begin{pmatrix} \pi_i \\ \pi_j \end{pmatrix} \quad (2.9)$$

- λ , que representa o próprio modelo de forma compactada, comumente denotado por $\lambda = (A, B, \pi)$.

A simples definição desses componentes não é suficiente para a análise preditiva, é preciso que o modelo seja capaz de interagir com os dados reais. Isso nos leva aos três desafios operacionais que permitem ao HMM realizar inferências e aprendizado.

2.1.7.3 Avaliação, Decodificação e Aprendizado

Segundo Rabiner (1989), para que os HMMs sejam úteis em aplicações reais, é necessário solucionar três problemas fundamentais, que se apresentam da seguinte forma:

- **Problema 1 (Avaliação):** Dada uma sequência de observações $O = O_1 O_2 \dots O_t$ e um modelo $\lambda = (A, B, \pi)$, como calculamos eficientemente $P(O|\lambda)$, isto é, a probabilidade de ocorrência da sequência de observações dado o modelo? (RABINER, 1989)

O primeiro problema apresenta-se como um problema de avaliação, no qual, dada uma sequência de observações, como calcular a probabilidade de ela ter sido produzida pelo modelo? Esse problema também pode ser analisado pela perspectiva de seleção de modelos, em que se avaliam diferentes modelos com o objetivo de identificar qual obtém a maior probabilidade de ter gerado as observações fornecidas.

- **Problema 2 (Decodificação):** Dada a sequência de observações $O = O_1 O_2 \dots O_t$, e o modelo $\lambda = (A, B, \pi)$, como escolhemos uma sequência de estados correspondente $Q = q_1 q_2 \dots q_t$ que seja ótima? Ou seja, que maximize a probabilidade da ocorrência da sequência observada. (RABINER, 1989)

O segundo problema representa aquilo que buscamos de fato ao utilizar um modelo treinado HMM. Fundamentalmente, o objetivo em um HMM é descobrir qual é

a sequência de estados ocultos que melhor explica (maximiza a probabilidade de) termos obtido a sequência observada O .

- **Problema 3 (Aprendizado):** Como ajustamos os parâmetros do modelo $\lambda = (A, B, \pi)$ para maximizar $P(O|\lambda)$? (RABINER, 1989)

O Problema 3 refere-se ao treinamento do HMM, no qual buscamos otimizar os parâmetros do modelo $\lambda = (A, B, \pi)$ para descrever da melhor forma possível como uma sequência de observações é gerada. Esse problema é fundamental pois nos permite adaptar o modelo aos dados reais e, assim, otimizar suas previsões.


As soluções para os problemas descritos são resolvidas através de algoritmos fundamentados em programação dinâmica, como os algoritmos *Forward*, *Viterbi* e *Baum-Welch*. O uso destes algoritmos torna o HMM uma solução computacionalmente viável, a subseção a seguir é dedicada às especificidades de cada um desses algoritmos e à sua utilidade na estrutura do modelo.

2.1.7.4 Algoritmos clássicos

2.1.7.4.1 Algoritmo *Forward*

O algoritmo *Forward* é utilizado para a resolução do primeiro problema descrito na seção anterior (Avaliação). Ele utiliza programação dinâmica, empregando uma tabela para armazenar valores intermediários conforme constrói a probabilidade da sequência de observações. O algoritmo calcula a probabilidade de obtermos aquela observação somando, de maneira eficiente, as probabilidades de todos os caminhos de estados ocultos possíveis que poderiam gerar aquela sequência de estados observados (JURAFSKY; MARTIN, 2026).

Figura 5 – Representação do processo do algoritmo *Forward* para uma sequência de três observações.



Fonte: (JURAFSKY; MARTIN, 2026)

Cada célula da Figura 5, denotada por $\alpha_t(j)$, representa a probabilidade de estar num estado j no instante t dadas as observações anteriores. O valor de cada célula $\alpha_t(j)$ é calculado através da soma das probabilidades dos caminhos que levam até ela (JURAFSKY; MARTIN, 2026):

$$\alpha_t(j) = P(o_1, o_2, \dots, o_t, q_t = j | \lambda) \quad (2.10)$$

Onde q_t representa o estado no instante t , sendo este um estado oculto do sistema, e λ representa os parâmetros do modelo. O valor para a célula $\alpha_t(j)$ é dado pela soma das probabilidades de todos os caminhos que nos levam até à mesma; portanto, para um estado j , o valor de $\alpha_t(j)$ é calculado da seguinte forma (JURAFSKY; MARTIN, 2026):

$$\alpha_t(j) = \sum_{i=1}^N \alpha_{t-1}(i) a_{ij} b_j(o_t) \quad (2.11)$$

Onde os fatores da multiplicação são:

- $\alpha_{t-1}(i)$: Representa o valor de probabilidade *forward* acumulado para o estado i no instante de tempo anterior ($t - 1$).
- a_{ij} : Representa a probabilidade de transição do estado i para o estado j (dada pela matriz de probabilidades de transição A do modelo).
- $b_j(o_t)$: A probabilidade de emissão da observação o_t dado o estado j .

2.1.7.4.2 Algoritmo de Viterbi

O algoritmo de Viterbi é responsável por solucionar o problema de Decodificação de HMMs. O algoritmo nos dá a sequência de estados ocultos que maximizam as probabilidades de termos uma sequência de observações O .

Tentar encontrar a melhor sequência calculando a probabilidade de todas as combinações possíveis de estados ocultos (por exemplo, executando o algoritmo *Forward* para cada combinação) exigiria um esforço computacional inviável, com um número exponencial de caminhos. Para contornar essa limitação, o algoritmo de Viterbi, de maneira similar ao *Forward*, também é um algoritmo de programação dinâmica (JURAFSKY; MARTIN, 2026), porém, a principal diferença reside no fato de que o algoritmo de Viterbi seleciona apenas o caminho de probabilidade máxima em cada etapa. Cada célula, denotada por $v_t(j)$, representa a probabilidade de o modelo estar no estado j no instante t , tendo percorrido a sequência de estados mais provável até aquele momento (JURAFSKY; MARTIN, 2026), $v_t(j)$ é representado da seguinte maneira:

$$v_t(j) = \max_{q_1, \dots, q_{t-1}} P(q_1 \dots q_{t-1}, o_1, o_2 \dots o_t, q_t = j | \lambda) \quad (2.12)$$

A probabilidade de Viterbi para um estado j no instante atual t é obtida extraindo a maior extensão possível dos caminhos anteriores: (JURAFSKY; MARTIN, 2026)

$$v_t(j) = \max_{i=1}^N v_{t-1}(i) a_{ij} b_j(o_t) \quad (2.13)$$

Os três fatores responsáveis por estender o caminho e calcular a probabilidade na Equação 2.13 são:

- $v_{t-1}(i)$: A probabilidade do caminho mais provável até o estado i no instante de tempo anterior ($t - 1$).
- a_{ij} : A probabilidade de transição do estado i para o estado atual j (obtida da matriz de transição A).
- $b_j(o_t)$: A probabilidade de emissão da observação o_t dado que o modelo se encontra no estado j .

2.1.7.4.3 Algoritmo de Baum-Welch

O algoritmo de Baum-Welch é utilizado para a resolução do problema de aprendizado inerente aos HMMs. Este problema consiste em estimar os parâmetros do modelo λ , ou seja, as matrizes de transição dos estados ocultos (A) e das probabilidades de emissão (B), dada uma sequência de observações O e uma sequência de potenciais estados ocultos Q .

O método é um caso especial do algoritmo de Maximização da Expectativa (do inglês *Expectation-Maximization* ou EM). Se trata de um algoritmo iterativo que calcula uma estimativa inicial para as probabilidades, em seguida, utiliza essas estimativas para derivar probabilidades cada vez melhores até que ocorra a convergência.

Para um HMM real, não é possível calcular as contagens das transições e emissões diretamente de uma sequência de observações, pois os caminhos de estados percorridos pela máquina são ocultos. O algoritmo de Baum-Welch contorna essa limitação estimando essas contagens de forma iterativa. Ele faz isso calculando a probabilidade *forward* para uma observação e, em seguida, dividindo essa probabilidade entre todos os diferentes caminhos que contribuíram para ela. Para que isso seja possível, além da probabilidade *forward* (α), o algoritmo requer a definição de uma probabilidade *backward* (β) (JURAFSKY; MARTIN, 2026).

A probabilidade *backward*, denotada por $\beta_t(i)$, é a probabilidade de observar a sequência do instante $t + 1$ até o final (T), dado que o modelo está no estado i no instante t (e dado o modelo λ):

$$\beta_t(i) = P(o_{t+1}, o_{t+2} \dots o_T \mid q_t = i, \lambda) \quad (2.14)$$

Assim como no algoritmo *forward*, o cálculo da probabilidade *backward* é realizado em três etapas:

1. Inicialização:

$$\beta_T(i) = 1, \quad 1 \leq i \leq N \quad (2.15)$$

2. Recursão:

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad 1 \leq i \leq N, \quad 1 \leq t < T \quad (2.16)$$

3. Término:

$$P(O | \lambda) = \sum_{j=1}^N \pi_j b_j(o_1) \beta_1(j) \quad (2.17)$$

A partir da combinação das variáveis *forward* (α) e *backward* (β), o algoritmo de Baum-Welch é capaz de calcular a probabilidade de estar em um estado específico em um dado momento, ajustando iterativamente os parâmetros do modelo para maximizar a probabilidade da sequência de observações fornecida no treinamento (JURAFSKY; MARTIN, 2026).

2.1.7.5 Aplicações de HMM em mercados financeiros e detecção de regimes

Dado o funcionamento e as características dos modelos preditivos que iremos utilizar para alcançar os objetivos do trabalho, é de fundamental importância entender como iremos tratar os dados de retorno da série temporal do Bitcoin para a realização do treinamento dos modelos. A próxima seção é dedicada a como iremos tratar e preparar os dados para estes modelos.

2.1.8 Discretização e representação simbólica de séries temporais

2.1.8.1 Por que discretizar os retornos

A discretização consiste no processo de projetar dados contínuos e sequenciais em um espaço simbólico finito, por meio de padrões probabilísticos concisos que comprimem a informação preservando seu conteúdo essencial (JHA, 2021). No contexto deste trabalho, essa transformação é mais do que uma escolha metodológica, trata-se de um requisito operacional, uma vez que as Cadeias de Markov são definidas sobre um espaço de estados discreto. A análise da série de retornos do Bitcoin necessita que cada observação contínua seja mapeada em um símbolo pertencente a um alfabeto finito.

Além da exigência operacional imposta pelo modelo, há uma motivação empírica relevante para a discretização. Conforme foi demonstrado por Scaillet, Treccani e Trevisan (2020), o comportamento dos ativos do mercado de criptomoedas é fortemente contaminado por ruídos de microestrutura e transações. Este ruído compromete a análise contínua dos retornos quando analisados em janelas de alta frequência, podendo ser mitigado através de técnicas de discretização que eliminam pequenas flutuações causadas por ruídos.

2.1.8.2 Estratégia de discretização dos dados

De maneira similar a [Araújo e Barbosa \(2024\)](#), a discretização será aplicada sobre os retornos logarítmicos da série temporal do Bitcoin 2.1 em janelas de cinco minutos. Calcularemos a média e desvio padrão dos retornos normalizados e definiremos a seguinte relação:

$$\begin{aligned} (r(t) - \bar{r}) &< -\frac{s}{3} \iff -1 \\ -\frac{s}{3} &\geq (r(t) - \bar{r}) \geq \frac{s}{3} \iff 0 \\ (r(t) - \bar{r}) &> \frac{s}{3} \iff 1 \end{aligned} \quad (2.18)$$

onde $r(t)$ é o retorno logarítmico no instante t , $\bar{r}$ é a média amostral dos retornos da série e s é o desvio padrão amostral. Os símbolos -1 , 0 e 1 representam os movimentos de queda significativa, oscilações pouco expressivas em torno da média e movimentos de alta significância, é necessário ressaltar que o trabalho avaliará a sensibilidade dos modelos também a limiares mais estreitos, como $\frac{s}{4}$ e $\frac{s}{5}$, o objetivo é garantir que o estado 0 represente exclusivamente o ruído branco da microestrutura do mercado, reduzindo o desbalanceamento das classes. A discretização será aplicada separadamente sobre dois conjuntos distintos obtidos através da série dos retornos logarítmicos, conjunto de treinamento e teste, de maneira similar a [Nascimento et al. \(2023b\)](#), 95% da série será separado para o treinamento dos modelos de predição e 5% será reservado para o teste.

2.1.8.3 Granularidade e viabilidade estatística

Conforme conclui [Nascimento et al. \(2023a\)](#), o custo computacional de treinamento de modelos de Cadeia de Markov de ordens superiores é de $O(n^{m+1})$, onde n representa a granularidade do alfabeto discreto e m a ordem da cadeia de Markov. Para entendermos a magnitude da complexidade da solução, considere um alfabeto de três símbolos. Uma cadeia de ordem 1 possui $3^2 = 9$ probabilidades de transição, já uma cadeia de ordem 4 terá $3^5 = 243$, e uma cadeia de ordem 6, $3^7 = 2.187$. Caso o alfabeto seja expandido para cinco símbolos, a mesma ordem 6 exige $5^7 = 78.125$. O crescimento exponencial, como conclui [Nascimento et al. \(2023a\)](#), traz limites computacionais que tornam o uso de cadeias de ordens superiores restrito à complexidade do alfabeto simbólico construído e à dimensão do modelo em si. O modelo proposto por [Raftery \(1985\)](#), reduz a complexidade para $O(mn^2 + m)$, para um modelo de cinco símbolos e cadeia de ordem 6 teríamos $6 \cdot 5^2 + 6 = 156$, uma redução significativa de probabilidades de transição.

A adoção do modelo de [Raftery \(1985\)](#) contorna o crescimento exponencial e torna as cadeias de Markov de ordem superior aplicáveis a cenários dinâmicos. No entanto, em um ambiente real é necessário que o modelo possua real poder preditivo sobre os estados futuros. Dessa forma, para atestar a qualidade das previsões geradas pela cadeia, faz-se necessária a utilização de métricas de validação específicas. A metodologia para

realizar essa aferição será discutida no tópico seguinte, que aborda a Avaliação de Modelos Preditivos em Séries Temporais.

2.1.9 Avaliação de modelos preditivos em séries temporais

2.2 Trabalhos relacionados

2.2.1 Trabalho 1: Reconstructing Cryptocurrency Processes via Markov Chains

O estudo de [Araújo e Barbosa \(2024\)](#), intitulado *Reconstructing Cryptocurrency Processes via Markov Chains* e publicado no periódico *Computational Economics (Springer Nature)*, possui forte alinhamento com os objetivos deste trabalho. A pesquisa busca reconstruir e prever os processos estocásticos de três das principais criptomoedas do mercado Bitcoin, Ethereum e Ripple, investigando a existência de componentes de memória de longo alcance em suas séries temporais ([ARAÚJO; BARBOSA, 2024](#)).

A motivação dos autores é tanto técnica quanto empírica. Eles constataam a inviabilidade estatística de utilizar livremente Cadeias de Markov de ordem elevada na predição de séries financeiras, uma vez que o número de combinações possíveis (blocos) cresce exponencialmente com o aumento da ordem, superando rapidamente o tamanho da amostra disponível.

Para contornar essas limitações, a análise é fundamentada em fechamentos intradiários de uma hora. Inicialmente, os autores utilizam um alfabeto discreto de cinco símbolos, construído com base na média ($\overline{r(t)}$) e no desvio padrão (s) dos retornos, estruturado da seguinte forma:


$$\begin{aligned}
 (r(t) - \overline{r(t)}) > s &\iff 2 \\
 s \geq (r(t) - \overline{r(t)}) > \frac{s}{3} &\iff 1 \\
 \frac{s}{3} \geq (r(t) - \overline{r(t)}) > -\frac{s}{3} &\iff 0 \\
 -\frac{s}{3} \geq (r(t) - \overline{r(t)}) > -s &\iff -1 \\
 -s \geq (r(t) - \overline{r(t)}) &\iff -2
 \end{aligned} \tag{2.19}$$

Mesmo com o alfabeto de cinco caracteres, observou-se que o crescimento exponencial inerente às cadeias de alta ordem compromete a viabilidade estatística do modelo para dimensões $k \geq 4$. Nesse ponto, o tamanho da amostra de treinamento torna-se inferior ao conjunto de possibilidades, o que faria o modelo falhar diante de sequências de observações inéditas.

Para mitigar esse problema, [Araújo e Barbosa \(2024\)](#) adotam a abordagem proposta por [Mendes, Lima e Araújo \(2002\)](#), conhecida como *Less-than-k-Markov*. Esse método recorre a probabilidades de matrizes de ordens menores $\{k-1, k-2, k-3, \dots, 2\}$ de forma

iterativa quando uma sequência específica de tamanho k não é encontrada na amostra histórica.

Figura 6 – Comparação do número de ocorrências de sequências de tamanho k para 5^k




Fonte: (ARAÚJO; BARBOSA, 2024), adaptado pelos autores

Os autores concluem, através da análise de acurácia do modelo para o alfabeto de cinco símbolos, que o algoritmo performa consistentemente melhor em comparação ao modelo de predição aleatório para todas as criptomoedas utilizadas na análise, conforme ilustrado na Figura 7. Esse comportamento sugere que o componente de memória de curto prazo se manifesta de maneira robusta e similar no mercado de ativos digitais.


Influenciados pela necessidade de caracterizar de maneira mais satisfatória a presença de pequenas flutuações e ruídos, além de buscar uma melhora na estabilidade estatística do treinamento, os autores testaram uma segunda configuração utilizando um alfabeto discreto constituído de três símbolos

$$\begin{aligned}
 (r(t) - \overline{r(t)}) > s &\iff 1 \\
 s \geq (r(t) - \overline{r(t)}) > -s &\iff 0 \\
 -s \geq (r(t) - \overline{r(t)}) &\iff -1
 \end{aligned} \tag{2.20}$$

Ao agrupar flutuações pouco expressivas em torno da média, essa estratégia desconsiderou ruídos irrelevantes de alta frequência. Como resultado, observou-se uma diminuição significativa nos erros obtidos na predição, estendendo a vantagem do modelo empírico para blocos de ordens maiores e preservando a identificação de componentes de memória de curto e longo alcance.

Figura 7 – Erro médio obtido na predição para k dimensões e 5 símbolos

Fonte: (ARAÚJO; BARBOSA, 2024)

Figura 8 – Erro médio obtido na predição para k dimensões e 3 símbolos

Fonte: (ARAÚJO; BARBOSA, 2024)

O presente trabalho utilizará um alfabeto discreto construído de maneira metodologicamente similar ao referencial de três símbolos conforme apresentado na Seção 2.1.8.2. Porém, a análise intradia será realizada para uma escala de alta frequência, utilizando fechamentos em janelas de cinco minutos.

Para contornar a explosão combinatória e os limites computacionais que restringiram o avanço da ordem preditiva no estudo de Araújo e Barbosa (2024), esta pesquisa empregará a modelagem baseada em Cadeias de Markov de alta ordem proposta por Raftery (1985). A adoção deste modelo reduz a complexidade para uma taxa linear, tornando viável a investigação de dependências temporais em ordens substancialmente maiores do que as apresentadas na literatura de referência, sem sacrificar a confiabilidade preditiva do sistema.

2.2.2 Trabalho 2: Extracting Rules via Markov Chains for Cryptocurrencies Returns Forecasting

O estudo de Nascimento et al. (2023a), intitulado Extracting Rules via Markov Chains for Cryptocurrencies Returns Forecasting e publicado no periódico Computational Economics, possui forte alinhamento com os objetivos deste trabalho. Em sua pesquisa, os autores utilizam Cadeias de Markov de alta ordem para extrair regras das dinâmicas de retorno de quatro criptomoedas do mercado: Bitcoin, Ethereum, Litecoin e Ripple. O estudo analisou os preços diários de fechamento em dólar, no período de 1º de outubro de 2016 a 30 de novembro de 2019, totalizando 1156 observações para cada ativo.

A principal motivação do estudo é determinar possíveis cenários futuros analisando a dependência de memória na dinâmica do processo, obtendo regras de transição de estados a partir das informações do conjunto de dados. Para isso, os autores constroem um modelo preditivo baseado nos retornos logarítmicos dos preços através da equação $r_t = \log(z_t) - \log(z_{t-1})$, onde z_t corresponde ao valor observado no dia atual e z_{t-1} ao valor observado no dia anterior.

Para realizar a análise, Nascimento descreve a necessidade de categorizar a série e enfatiza que a granularidade dos dados pode influenciar os resultados. Desse modo, foram testadas quatro granularidades (0,1; 0,01; 0,001 e 0,0001) com a finalidade de discretizar os retornos e encontrar o melhor ajuste para as séries temporais. Essas granularidades representam os intervalos numéricos onde a série será categorizada, sendo o escopo total definido entre o menor e o maior valor da série temporal, subtraindo e somando o valor da respectiva granularidade.

Uma vez que a série temporal é classificada, os autores definem os estados de transição da matriz de forma que o número de estados para cada granularidade seja equivalente ao número total de categorias menos um. Como exemplo, para a série do Bitcoin com granularidade 0,1, o intervalo de categorização obtido foi de $[-0,286095194; 0,324052773]$.

Nesse cenário, foram geradas seis categorias, resultando em cinco possíveis estados para a matriz de transição.

Para validar o modelo, o estudo utilizou três métricas: a Raiz do Erro Quadrático Médio, do inglês *Root Mean Square Error* (RMSE), o Erro Médio Absoluto, do inglês *Mean Absolute Error* (MAE) e o Erro Percentual Absoluto Médio, do inglês *Mean Absolute Percentage Error* (MAPE). O RMSE e o MAE foram utilizados para determinar qual ordem da Cadeia de Markov obteve a melhor acurácia dentro de cada granularidade, enquanto o MAPE auxiliou na escolha da granularidade ideal. Nascimento conclui que, para o Bitcoin, um processo de Markov na sétima ordem produz os melhores resultados, corroborando a hipótese de que as séries temporais de criptomoedas possuem memória de longo alcance.

O presente trabalho também utilizará processos de Markov de alta ordem e também modelos ocultos de Markov, porém com foco em modelos preditivos direcionais. Para isso, será adotado um alfabeto constituído por três símbolos, diferindo metodologicamente do estudo de Nascimento, que utilizou intervalos contínuos baseados em granularidade. A adoção de um alfabeto discreto e reduzido evita o problema de explosão de estados e complexidade computacional encontrado por Nascimento et al. (2023a) em granularidades muito baixas. Como o objetivo desta pesquisa difere da predição de valores absolutos, a validação dos modelos direcionais será feita por meio de métricas adequadas a problemas de classificação, tais como Matriz de Confusão, Acurácia, Precisão e F1-Score. Por fim, a janela de tempo analisada também se difere do fechamento diário utilizado na literatura supracitada; com base nas observações de Gonzalez de Freitas Pinto (2025), este trabalho adotará janelas de fechamento de cinco minutos, consideradas mais adequadas para a análise de séries temporais do Bitcoin.

2.2.3 Trabalho 3: Bitcoin price prediction using machine learning: An approach to sample dimension engineering

O estudo de Chen (2025), intitulado *Bitcoin price prediction using machine learning: An approach to sample dimension engineering* e publicado no periódico *Journal of Computational and Applied Mathematics*, possui forte alinhamento com os objetivos deste trabalho. Em seu trabalho Chen (2025) busca definir os melhores métodos de aprendizado de máquina para predição de preços para o Bitcoin. Chen (2025) divide a amostra de predição em uma amostra pequena de fechamentos diários e uma amostra maior de fechamento de 5 minutos. Os autores expressam que essa decisão se deve à estrutura diferente dos dados e que aplicar modelos de aprendizado de máquina de forma incorreta gera um erro nos modelos chamado sobreajuste (*overfitting*). Então os autores empregam modelos estatísticos para o fechamento diário do preço do Bitcoin, enquanto utilizam de métodos de aprendizado de máquina para a amostra de alta frequência, ou seja, fechamentos de

cinco minutos.

Além da preocupação com a dimensionalidade da amostra, os autores transformam o desafio preditivo em um problema de classificação binária, focando exclusivamente em prever a direção (mudança de sinal) do preço do ativo. A justificativa é que a predição direcional é mais prática para fundamentar decisões de negociação no mercado financeiro. Por se tratar de um problema de classificação direcional, o desempenho dos modelos foi validado por meio de uma Matriz de Confusão e métricas específicas, como Acurácia, Precisão, Revocação e F1-Score.

O presente trabalho corrobora a utilidade da janela de cinco minutos para capturar as dinâmicas de alta frequência e adota o foco direcional estabelecido por [Chen \(2025\)](#), outro ponto em comum é a utilização de um alfabeto para classificar a série temporal, que no presente trabalho é um alfabeto composto por três símbolos diferindo-se da metodologia de [Chen \(2025\)](#), o presente trabalho também utilizará das métricas empregadas pelos autores com a finalidade de validar os modelos empregados. Contudo, diferentemente do uso de algoritmos de aprendizado de máquina em larga escala, esta pesquisa se propõe a modelar o comportamento direcional do Bitcoin utilizando Cadeias de Markov de alta ordem e modelos ocultos de Markov. Essa abordagem estocástica permite extrair a dependência temporal e as regras de transição inerentes aos retornos de cinco minutos de forma clara, reduzindo a complexidade computacional exigida por modelos tradicionais de aprendizado de máquina, ao mesmo tempo em que mantém o rigor na avaliação preditiva através do uso das métricas de classificação adequadas.

2.2.4 Síntese Comparativa

A análise individual de cada um dos trabalhos relacionados permite compreender com maior clareza o posicionamento desta pesquisa no cenário acadêmico atual, bem como suas diferenças em relação às abordagens comumente adotadas na literatura. A Tabela 1 sintetiza os principais pontos de divergência entre os trabalhos analisados e as metodologias empregadas por seus respectivos autores.

Tabela 1 – Comparação entre trabalhos relacionados

Critério	Araújo e Barbosa (2024)	Nascimento (2023)	Chen (2025)	Este trabalho
Objetivo	Reconstruir processos de criptoativos e detectar memória de longo alcance	Prever retornos futuros de quatro criptomoedas via Cadeias de Markov	Prever a direção do preço do Bitcoin comparando algoritmos de <i>ML</i>	Prever a direção do BTC e identificar a ordem em que a memória se torna relevante
Ativos	Bitcoin, Ethereum e Ripple	Bitcoin, Ethereum, Ripple e Litecoin	Bitcoin	Bitcoin
Fechamento	1 hora	24 horas	Diária e intradiária (5 min)	Intradiária (5 min)
Modelagem	Cadeias de Markov de alta ordem (<i>less-than-k</i>)	Cadeias de Markov (1ª à 10ª ordem)	Regressão logística, LDA, QDA, SVM, XGBoost e LSTM	Cadeias de Markov de alta ordem (MTD/Raftery) e HMM
Discretização	Alfabetos de 5 e 3 símbolos	Multiplos Alfabetos	Binária (direção)	Alfabeto de 3 símbolos (limiares $s/3$, $s/4$, $s/5$)
Validação	Erro médio <i>vs.</i> modelo aleatório	RMSE, MAE e MAPE	Acurácia, precisão, <i>recall</i> e <i>F1-score</i>	Acurácia, precisão, <i>recall</i> , F1 e matriz de confusão <i>vs.</i> <i>baselines</i>
Limitação	Explosão combinatória limita a ordem ($k \geq 4$)	Memória limita a análise até a 10ª ordem	Granularidade e número de dimensões	—

Fonte: Elaborado pelos autores (2026)

3 Desenvolvimento

Este capítulo apresenta a proposta de desenvolvimento metodológico desta pesquisa, detalhando os passos fundamentais planejados para alcançar o objetivo principal do projeto. Sendo o foco estruturar a solução proposta, a seção descreve como deverão ser conduzidas a coleta de dados, a modelagem preditiva baseada em Cadeias de Markov de Alta Ordem e Modelos Ocultos de Markov, do inglês *Hidden Markov Model* (HMM), e a avaliação de desempenho. Todas as decisões tecnológicas e arquiteturais delineadas para a etapa de implementação são fundamentadas na revisão bibliográfica discutida no Capítulo 2.

3.1 Solução proposta

3.1.1 Visão geral da solução

A solução proposta consiste na implementação de um modelo de predição direcional para a série temporal do Bitcoin em janelas de cinco minutos, baseado em Cadeias de Markov de Alta Ordem segundo a formulação de [Raftery \(1985\)](#). O desempenho desse modelo será comparado ao de três modelos de referência, o HMM, o modelo de predição aleatório e o modelo de predição por persistência. Todos os modelos serão treinados a partir de uma série discreta, obtida pela discretização dos retornos logarítmicos da série temporal do Bitcoin em um alfabeto de três símbolos (-1 , 0 e 1), conforme a estratégia apresentada na subseção [2.1.8.2](#). Por fim, os modelos treinados serão submetidos a testes estatísticos sobre o conjunto de teste, a fim de validar sua capacidade preditiva por meio de métricas de classificação acurácia, precisão, *recall*, *F1-score* e matriz de confusão, conforme discutido na seção [2.1.9](#).


3.1.2 Pipeline da Solução

- **Coleta dos dados fornecidos pela *Binance*:** Os dados serão coletados com o fechamento em janelas de cinco minutos, durante um período de 9 anos, obtendo aproximadamente 920 mil registros.
- **Tratamento e discretização dos dados:** Os dados são discretizados utilizando a estratégia apresentada em [2.1.8.2](#), assim obtendo uma nova série temporal de símbolos pertencentes ao alfabeto simbólico, a qual será repartida em conjunto de treinamento e teste.
- **Separação dos Dados Históricos:** Considerando a evolução estrutural de criptoativos que os fez sair de um nicho tecnológico para um fenômeno financeiro global

(MAKAROV; SCHOAR, 2022), será realizada a divisão do conjunto de dados em subamostras menores. Como as séries financeiras naturalmente apresentam quebras estruturais, alternando entre fases de alta, baixa e lateralização que afastam a propriedade de estacionariedade em longas janelas de tempo (MORETTIN; TOLOI, 2018), o intuito dessa divisão é mitigar um possível viés de homogeneidade.

- **Treinamento e adequação dos Modelos Preditivos:** O conjunto de treinamento agora já construído será utilizado para o treinamento dos modelos preditivos.
- **Testes Estatísticos, Comparações e Predição:** Os modelos de predição agora já treinados irão realizar as predições sobre o conjunto de dados separado para os testes. Os modelos terão sua adequação avaliada através dos métodos estatísticos descritos na seção 2.1.9.

Figura 9 – Pipeline da solução proposta




Fonte: Elaborado pelos autores (2026)

3.2 Cronograma de trabalho

O cronograma apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre, conforme ilustrado na Figura 10.

Figura 10 – Cronograma de atividades – Diagrama de Gantt



Fonte: Elaborado pelos autores (2026)

Referências

ARAÚJO, T.; BARBOSA, P. Reconstructing cryptocurrency processes via markov chains. *Computational Economics*, v. 64, n. 4, p. 2509–2521, 2024. ISSN 1572-9974. Disponível em: <<https://doi.org/10.1007/s10614-023-10512-1>>. 7, 8, 29, 30, 31, 32, 33

Ben Omrane, W. et al. Exploring volatility reactions in cryptocurrency markets using intraday macroeconomic news analysis. *International Review of Economics & Finance*, v. 103, p. 104509, 2025. ISSN 1059-0560. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1059056025006720>>. 15

BLAU, B. M.; GRIFFITH, T. G.; WHITBY, R. J. Inflation and bitcoin: A descriptive time-series analysis. *Economics Letters*, v. 203, p. 109848, 2021. ISSN 0165-1765. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0165176521001257>>. 7

CATANIA, L.; SANDHOLDT, M. Bitcoin at high frequency. *Journal of Risk and Financial Management*, MDPI, v. 12, n. 1, 2019. 8

CHEN, Z. From disruption to integration: Cryptocurrency prices, financial fluctuations, and macroeconomy. *Journal of Risk and Financial Management*, v. 18, n. 7, p. 360, 2025. ISSN 1911-8074. Disponível em: <<https://www.mdpi.com/1911-8074/18/7/360>>. 7, 34, 35

CHUEN, D. L. K. *Handbook of Digital Currency: Bitcoin, Innovation, Financial Instruments, and Big Data*. San Diego: Academic Press, 2024. 6, 7, 12, 13, 14

DYMARSKI, P. *Hidden Markov Models: Theory and Applications*. 1. ed. Rijeka: IntechOpen, 2011. 22

Financial Action Task Force. *Virtual Currencies: Key Definitions and Potential AML/CFT Risks*. Paris: [s.n.], 2014. <<http://www.fatf-gafi.org/media/fatf/documents/reports/Virtual-currency-key-definitions-and-potential-aml-cft-risks.pdf>>. Acesso em: 7 maio 2026. 12

FISZ, M. *Probability Theory and Mathematical Statistics*. 3rd. ed. New York: John Wiley & Sons, 1963. Translated by Robert Bartoszyński. 18, 19

GHAHRAMANI, Z. An introduction to hidden markov models and bayesian networks. *International Journal of Pattern Recognition and Artificial Intelligence*, v. 15, n. 1, p. 9–42, 02 2001. 22

Gonzalez de Freitas Pinto, M. High-frequency dynamics of bitcoin futures: An examination of market microstructure. *Borsa Istanbul Review*, v. 25, n. 6, p. 1378–1390, 2025. ISSN 2214-8450. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2214845025001188>>. 15, 34

JHA, D. K. *Markov Modeling of Time-Series Data Using Symbolic Analysis*. 2021. 28

- JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. 3rd. ed. Stanford: [s.n.], 2026. Manuscrito online publicado em 6 de Janeiro, 2026. 22, 25, 26, 27, 28
- KUINCHTNER, D.; MADALOZZO, G. A. *Predição do Mercado de Ações Usando Hidden Markov Model*. Passo Fundo: [s.n.], 2018. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Universidade de Passo Fundo (UPF), Passo Fundo, 2018. 23
- MA, Y. et al. The hidden markov model and its applications in bioinformatics analysis. *Genes & Diseases*, v. 13, p. 101729, 2026. ISSN 2352-3042. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2352304225002181>>. 22
- MAKAROV, I.; SCHOAR, A. Cryptocurrencies and decentralized finance (defi). *SSRN Electronic Journal*, 01 2022. 6, 8, 38
- MALEKINEZHAD, H.; RAFATI, R. *Markov and Hidden Markov Models for Regime Detection in Cryptocurrency Markets: Evidence from Bitcoin (2024–2026)*. Preprints.org, 2026. Preprint, Acesso em: 29 abr. 2026. Disponível em: <<https://doi.org/10.20944/preprints202603.0831.v1>>. 8
- MENDES, R. V.; LIMA, R.; ARAÚJO, T. A process-reconstruction analysis of market fluctuations. *International Journal of Theoretical and Applied Finance*, v. 5, n. 8, p. 797–821, 2002. Disponível em: <<https://doi.org/10.1142/S0219024902001730>>. 30
- MORETTIN, P.; TOLOI, C. *Análise de séries temporais: modelos lineares univariados*. BLUCHER., 2018. ISBN 9788521213529. Disponível em: <<https://books.google.com.br/books?id=UwC5DwAAQBAJ>>. 15, 16, 17, 38
- NAKAMOTO, S. *Bitcoin: A peer-to-peer electronic cash system*. 2008. Disponível em: <<https://bitcoin.org/bitcoin.pdf>>. 13, 14, 15
- NASCIMENTO, K. K. F. d. et al. Extracting rules via markov chains for cryptocurrencies returns forecasting. *Computational Economics*, v. 61, n. 3, p. 1095–1114, 2023. ISSN 1572-9974. Disponível em: <<https://doi.org/10.1007/s10614-022-10237-7>>. 7, 8, 9, 21, 29, 33, 34
- NASCIMENTO, K. K. F. do et al. Extracting rules via markov chains for cryptocurrencies returns forecasting. *Computational Economics*, v. 61, p. 1095–1114, 2023. 29
- PAPADOPOULOS, G. *Chapter 7 - Blockchain and digital payments: An institutionalist analysis of cryptocurrencies*. 2. ed. San Diego: Academic Press, 2024. 147–167 p. ISBN 978-0-323-98973-2. Disponível em: <<https://www.sciencedirect.com/science/article/pii/B9780323989732000307>>. 6, 12, 13
- PETUKHINA, A. A.; REULE, R. C. G.; HÄRDLE, W. K. Rise of the machines? intraday high-frequency trading patterns of cryptocurrencies. *The European Journal of Finance*, Routledge, v. 27, n. 1-2, p. 8–30, 2021. 7
- RABINER, L. R. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, v. 77, n. 2, p. 257–286, 1989. 23, 24, 25

- RAFTERY, A. E. A model for high-order markov chains. *Journal of the Royal Statistical Society. Series B (Methodological)*, Royal Statistical Society, v. 47, n. 3, p. 528–539, 1985. 21, 29, 33, 37
- ROSS, S. M. *Introduction to Probability Models*. 10th. ed. San Diego: Academic Press, 2010. ISBN 978-0-12-375686-2. 19, 20
- SCAILLET, O.; TRECCANI, A.; TREVISAN, C. High-frequency jump analysis of the bitcoin market. *Journal of Financial Econometrics*, v. 18, n. 2, p. 209–232, 2020. 28
- SILVA, L. P. Q. et al. Utilizando hmm para previsão de preço e estratégia de investimento em criptomoedas bitcoin. In: *Anais do 4º Workshop em Blockchain: Teoria, Tecnologias e Aplicações (WBLOCKCHAIN)*. Uberlândia: SBC, 2021. p. 134–147. 8
- URQUHART, A. The inefficiency of bitcoin. *Economics Letters*, v. 148, p. 80–82, 2016. ISSN 0165-1765. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0165176516303640>>. 7, 21